

C'est en raison de ses bonnes propriétés de résolution temps-fréquence, de stabilité aux déformations, et de sparsité que le scalogramme  $x_1(u_1, \lambda_1)$  est un outil de choix pour la classification de sons. Or, afin de pouvoir généraliser une classe de signaux à partir d'un nombre limité d'exemples, il est nécessaire de construire une représentation invariante par translation à l'échelle temporelle  $T$  des unités à classifier. Le scalogramme est une représentation *covariante* à la translation, bien qu'on puisse le rendre invariant en appliquant une moyenne glissante sur l'axe temporel. L'échelle  $T$  vaut typiquement 200 ms pour des notes de musique ou des syllabes ; pourtant, en raison de la nature transitoire des signaux de musique et de parole, les capacités de discrimination du scalogramme chutent dès que  $T$  dépasse 20 ms. Afin d'étendre cette limite, il s'agit de démoduler les oscillations du scalogramme  $x_1(u_1, \lambda_1)$  dont la période est inférieure à  $T$  ; encore une fois, on requiert une bonne stabilité à la variabilité naturelle des sons à l'intérieur d'une classe.

Compte tenu de ces observations, [Andén et Mallat, 2011] ont introduit la transformée de scattering pour les sons, comme le « scalogramme du scalogramme ». Pour toute fréquence  $\lambda_1$ , il s'agit de transformer  $x_1(u_1, \lambda_1)$  en ondelettes comme un signal unidimensionnel du temps  $u_1$ , et d'appliquer le module :

$$x_2(u_1, \lambda_1, \lambda_2) = |x_1(u_1, \lambda_1) * \psi_{\lambda_2}(u_1)|, \quad (1)$$

où  $\psi_{\lambda_2}(u_1)$  est une ondelette de fréquence centrale  $\lambda_2$  (en Hertz). La transformée de scattering capture explicitement les modulations d'amplitude du signal, ce qui a mené à des progrès considérables en classification de signaux. Cependant, elle n'est pas stable aux mouvement de hauteur au-delà de  $Q^{-1}$ , soit typiquement un seizième d'octave. Pour intégrer l'évolution de hauteur dans la transformée, on peut redéfinir  $x_2$  comme

$$x_2(u_2, \lambda_1, \lambda_2) = |x_1 * \psi_{\lambda_2}|(u_2),$$

où  $u_2$  est une variable générique construite à partir du temps  $u_1$  et de la fréquence  $\lambda_1$ . Il faut remarquer que cette équation est une généralisation du modèle original du scattering 1 : en écrivant  $u_2 = u_1$  et en factorisant l'action de  $\psi_{\lambda_2}(u_2)$  sur toutes les fréquences  $\lambda_1$ , on parvient à  $|x_1 * \psi_{\lambda_2}|(u_2)$ .

Le modèle cortical de [Patil et al.] effectue des transformées sur les déplacements joints en temps et en log-fréquence :  $u_2 = (u_1, \log_2 \lambda_1)$ . La variable de Fourier correspondante s'écrit  $\lambda_2 = (a, b)$  où  $a$  est la fréquence temporelle (en Hertz)  $u_1$  et  $b$  est la fréquence log-fréquentielle (en cycles par octave).

$$\psi_{\lambda_2}(u_1, \log_2 \lambda_1) = \psi_a(u_1) * \psi_b(\log_2 \lambda_1)$$

Nous proposons d'étendre ce modèle afin d'inclure la variabilité des déplacements sur les octaves. On pose donc  $u_2 = (u_1, \log_2 \lambda_1, \lfloor \log_2 \lambda_1 \rfloor)$  la variable de déplacement sur la spirale. La fréquence correspondante s'écrit  $\lambda_2 = (a, b, c)$  où  $a$  est la fréquence temporelle (en Hertz),  $b$  est la fréquence log-fréquentielle (en cycles par octave),  $c$  est la « fréquence selon les octaves » (en cycles par octave). L'expérience de Shepard nous apprend que, bien les fréquences  $b$  et

$c$  soient exprimées dans la même unité, elles correspondent à des phénomènes différents : avec typiquement  $|b^{-1}| < 1$  octave et  $|c^{-1}| > 1$  octave,  $b$  quantifie un déplacement angulaire sur la spirale tandis que  $c$  quantifie un déplacement radial. On propose d'appeler « ondelettes de Shepard » les produits séparables d'ondelettes sur la spirale  $u_2 = (u_1, \log_2 \lambda_1, \lfloor \log_2 \lambda_1 \rfloor)$  :

$$\psi_{\lambda_2}(u_1, \log_2 \lambda_1, \lfloor \log_2 \lambda_1 \rfloor) = \psi_a(u_1) * \psi_b(\log_2 \lambda_1) * \psi_c(\lfloor \log_2 \lambda_1 \rfloor).$$

Sur la figure 2, on a représenté deux ondelettes de Shepard  $\psi_{\lambda_2}$  pour différentes valeurs de fréquences  $a$ ,  $b$  et  $c$ .